

Progetto di Linguistica Computazionale II

A.A. 2025/2026

Linee guida

Obiettivo del progetto

Il progetto ha come finalità lo sviluppo di un sistema di classificazione testuale per affrontare il compito di *machine-generated text detection*, ovvero distinguere se un testo è stato scritto da un umano oppure generato automaticamente da un language model. Lo studente dovrà implementare diversi modelli di classificazione basati sugli approcci studiati a lezione, confrontarne le prestazioni e redigere una relazione dettagliata che descriva il lavoro svolto, le scelte metodologiche adottate e i risultati ottenuti.

Descrizione del compito

Sviluppare un classificatore di testi basato sui diversi approcci studiati a lezione, confrontando le prestazioni dei diversi sistemi.

Per l'addestramento e la valutazione dei modelli, utilizzare il dataset del task Desegma-IT (Detection and Segmentation of Machine Generated Text in Italian), proposto come shared task a EVALITA 2026. La descrizione completa del task e il dataset sono disponibili al seguente link: <https://desegma.github.io/>.

Il task originale è articolato in due sotto-task. Nel progetto è richiesto di affrontare esclusivamente il **primo sotto-task** (classificazione binaria a livello di documento), che riguarda la machine-generated text detection a livello di documento, in cui ciascun testo deve essere classificato come scritto da un umano oppure generato automaticamente.

Data la dimensione del dataset, è richiesto costruire un sottoinsieme dei dati per gli esperimenti. In particolare, lo studente dovrà estrarre minimo:

- 2000 documenti dal training set da utilizzare come training set,
- 1000 documenti dal training set da utilizzare come validation set,
- 1000 documenti dal test set da utilizzare come test set.

I tre corpora costruiti (training, validation e test set) dovranno essere bilanciati in termini di numero di documenti appartenenti alla classe 0 (scritto da un umano) e alla classe 1 (generato automaticamente con un language model).

Una volta preparati i dati, lo studente dovrà sviluppare diversi modelli di classificazione, implementati in Python sfruttando le diverse librerie di machine learning introdotte a lezione. Al

termine della sperimentazione, sarà necessario confrontare i risultati ottenuti dai diversi modelli in base alle metriche ritenute più opportune.

Infine, si richiede la redazione di una relazione che documenti tutte le fasi del progetto, dalla preparazione dei dati, allo sviluppo e valutazione dei modelli, fino alla discussione finale dei risultati, evidenziandone pregi, limiti e possibili miglioramenti.

Fasi di sviluppo del progetto

Una volta completata la costruzione dei dataset (training, validation e test set), lo studente è tenuto a sviluppare i classificatori richiesti e a condurre le analisi descritte di seguito.

1. Classificatore basato su SVM lineari e n-grammi.

Il primo classificatore dovrà essere costruito attraverso SVM lineari, utilizzando una rappresentazione del testo fondata su n-grammi di caratteri, parole e part-of-speech. Lo studente dovrà:

- sperimentare diverse configurazioni della rappresentazione testuale, variando sia la lunghezza degli n-grammi sia il tipo di informazione linguistica impiegata (forme, lemmi, caratteri, POS);
- effettuare una valutazione tramite procedura di cross-validation a 5 fold sul training set per selezionare il modello migliore;
- valutare le prestazioni del modello scelto attraverso la 5 fold cross-validation sui set di validazione e di test.

2. Classificatore basato su Support Vector Machine (SVM) lineari e informazioni linguistiche non lessicali.

Anche il secondo classificatore dovrà essere costruito utilizzando SVM lineari, ma impiegando come rappresentazione del testo esclusivamente informazioni linguistiche non lessicali, estratte tramite il sistema Profiling-UD. Per questo modello è richiesto di:

- valutare le prestazioni del modello sui set di validazione e di test;
- mostrare i 5 documenti del test set dove il modello è più incerto in fase di classificazione;
- fornire un elenco delle 20 feature più rilevanti ai fini della classificazione.

3. Classificatore basato su SVM lineari e word embedding.

Il terzo classificatore dovrà utilizzare una rappresentazione vettoriale del testo costruita a partire da word embeddings. I modelli di embedding da utilizzare potranno essere, ad esempio, quelli forniti dal sito ItaliaNLP Lab (<http://www.italianlp.it/resources/italian-word-embeddings>). In questo caso si richiede di:

- testare diverse rappresentazioni del testo che variano rispetto al modo di combinare gli embedding delle singole parole e/o rispetto alle categorie grammaticali delle parole prese in considerazione;
- valutare i vari modelli sul validation set;
- testare sul test set il sistema che ha ottenuto le migliori prestazioni nella fase di validazione.

4. Fine-tuning di un modello di linguaggio neurale (Neural Language Model).

Lo studente dovrà selezionare un neural language model tra quelli trattati durante il corso e condurre un processo di fine-tuning per un totale di 3 epoche. Per questa fase, è richiesto di:

- presentare le curve di loss relative al training e al validation set;
- riportare le prestazioni del modello sul validation set al termine di ciascuna epoca;
- valutare il modello sul test set al termine della terza epoca.

Risultati del progetto

Perché il progetto sia giudicato idoneo, devono essere consegnati:

1. Il codice sorgente dei programmi sviluppati, scritti in linguaggio Python e corredati da commenti esplicativi. Il codice può essere consegnato sia sotto forma di script .py, sia come file Jupyter Notebook.
2. La relazione in forma di report che descriva: il compito affrontato e le modalità di costruzione dei dataset; i modelli sviluppati e i risultati degli esperimenti richiesti; una discussione sui risultati ottenuti e sulle osservazioni emerse. La relazione deve avere una lunghezza approssimativa che va dalle 5 alle 10 pagine.

Date di consegna del progetto

Il progetto deve essere consegnato per posta elettronica a felice.dellorletta@ilc.cnr.it, e giulia.venturi@ilc.cnr.it almeno una settimana prima dell'orale di ogni appello per poter essere considerato valido per l'appello.

NB: il progetto **DEVE** essere svolto individualmente.